

MIRC701 實驗室研究主題與計畫訪談紀錄表

訪談日期：115 年 6 月 16 日 8 時 15 分

論文名稱：Distillation Footprints: Quantifying Degradation and Error Inheritance Risks in LLMs

(蒸餾足跡: 量化大語言模型的退化與錯誤繼承風險)

受訪者姓名：魏宇奐 (Vincent)

Q1: What problem does your research aim to solve? (你的研究想解決什麼問題?)

在黑箱以及未知模型身分的情境下，量化大語言模型因蒸餾造成的退化與錯誤繼承風險。

Q2: Why is this problem important? (為什麼這個問題重要?)

現有的測試基準(benchmark)只能量化模型本身的表現，若因蒸餾而出現能力或安全性上的風險則無從得知。

Q3: What are the limitations of existing approaches? (現有方法有哪些限制?)

大部分方法需要白箱進行分析，且所有方法都必須事先知道模型身分。

Q4: What is the key difference between your work and previous studies? (你的研究與現有研究最大的差異是什麼?)

過去研究多半只分析蒸餾現象或辨識模型來源，本研究則進一步將這些現象轉換成可量化的風險評估，而且不需要事先知道待測模型的身分。

Q5: Why did you choose black-box analysis instead of white-box analysis? (為什麼選擇黑箱分析而非白箱分析?)

在實際商業部屬情境中，使用者或客戶往往無法直接存取模型，只能存取輸入與輸出，對應黑箱情境。

Q6: Why does knowledge distillation lead to capability degradation? (為什麼蒸餾會造成能力退化?)

因蒸餾多以小模型去乘載大模型的知識，容易導致容量瓶頸造成僅學到形式邏輯而不是真正的推理能力，並造成罕見知識及證據利用能力的流失。

Q7: Why do student models inherit errors from teacher models? (為什麼模型會繼承教師模型錯誤?)

因為蒸餾的本質是讓學生模型模仿教師模型的行為，在這過程中學生模型會不分對錯地學習教師的知識，所以一旦從教師模型來的知識是錯誤的，學生模型也會學到。

Q8: What is the theoretical foundation of Distillation Footprint?

(Distillation Footprint 的理論基礎是什麼?)

蒸餾造成容量壓縮→表達能力受限→輸出多樣性下降→可觀測的語言風格痕跡→退化風險隨著這個痕跡同步上升

Q9: Why were lexical richness and dependency depth selected as features? (為什麼選擇 lexical richness 與 dependency depth 作為特徵?)

需要一個可以用單一值來量化的風格特徵，這兩個指標同時符合「表達輸出風格」以及「可量化」兩個條件，可做為語言風格痕跡的代表。

Q10: What are the potential applications of this framework in the future? (這套系統未來可應用在哪些場景?)

企業導入前的模型採購與驗收、模型上線前的風險分級與部署閘門、事故調查與模型來源追蹤，系統皆可作為導入前的獨立檢測工具，做到風險的快速預警。

Q11: Do you have any other important additions? (你有無其他重要補充?)

本研究的定位不是取代完整的 benchmark 或安全審核，而是提供一個低成本的快速預警工具。實驗顯示 Distillation Footprint 對一般用途模型的能力退化具有較強的預測效果，但對安全退化以及 MoE、CoT 等特殊架構的效果較有限，代表安全性還受到對齊方法與模型架構等因素影響，因此系統輸出的分數應被解讀為風險預警，而不是蒸餾因果關係的最終證明。未來可擴充更多模型家族與特殊架構，並控制更多干擾因素。